

第二章数据特征分析与 VaR 回测框架

2.1 数据来源与变量定义

本章首先对实证数据进行描述性统计和探索性分析，并在此基础上给出后续 VaR 预测模型的统一实证框架。本文使用 SPY 的日度收益率和高频波动率指标作为实证样本。样本区间为 2000-01-04 至 2018-06-27，共 4,640 个交易日。核心变量包括日对数收益率 `log_ret`、五分钟 realized volatility 指标 `rv5`，以及 bipower variation 指标 `bv`。其中 `log_ret` 是后续 VaR 预测的目标变量，`rv5` 和 `bv` 则用于刻画市场条件和波动状态，并为第五章的神经网络分位数模型提供可解释的波动率输入。

表 `section2_dataset_overview.csv` 汇总了样本范围、观测数量、缺失情况和后续 VaR 预测设定。样本中三个核心变量均可直接用于滚动窗口实证分析，因此后续模型可以在统一的数据口径下进行比较。需要强调的是，本章的探索性分析并非单纯的数据可视化，而是服务于后续模型选择：收益率分布特征决定是否需要非正态和非参数方法，波动聚集决定是否需要条件异方差模型，而高频波动率变量则决定神经网络模型是否具备额外信息输入。

2.2 收益率分布特征

表 `section2_descriptive_statistics.csv` 显示，SPY 日对数收益率的样本均值为 0.000133，标准差为 0.012013。从偏度和峰度看，收益率分布并不服从简单的正态假设：偏度为 -0.208，超额峰度为 8.219。Jarque-Bera 正态性检验的 p 值为 0，在常用显著性水平下拒绝正态分布假设。这说明若直接使用正态分布假设估计 VaR，可能低估极端损失发生的概率。

图 2-1 展示了日收益率时间序列，并标记低于经验 1% 分位数的极端下跌日。可以看到，尾部损失并非均匀分布，而是集中出现在市场压力阶段。图 2-3 和图 2-4 分别从直方图和 Q-Q 图角度进一步说明收益率存在尖峰厚尾和下尾偏离。因此，本文不能只依赖正态线性模型，而需要比较非参数历史模拟、厚尾 GARCH 和神经网络分位数模型。

从 VaR 角度看，经验 1%、5% 和 10% 分位数分别为 -0.034545、-0.018807 和 -0.012885。这些分位数为第三章历史模拟法提供了最直接的非参数基准，也说明了极端尾部样本数量有限，尤其是 1% VaR 的估计更容易受到窗口长度和市场状态变化影响。

2.3 波动聚集与市场状态

图 2-2 报告了 `annualized rv5` 与 `bv` 的时间序列，图 2-5 报告了 60 日滚动年化波动率。两个图共同说明，SPY 的波动率存在明显的状态转换和持续性：平稳阶段的波动率较低，而金融危机和其他市场压力阶段会形成显著的高波动区间。这一事实直接支持第四章引入 GARCH 类模型，因为 GARCH 模型的核心就是用条件方差动态刻画波动聚集。若不考虑条件波动率变化，模型在高波动阶段容易给出过于乐观的风险阈值。

表 `section2_volatility_regime_summary.csv` 将样本按 `rv5` 分成低、中、高三个波动状态。低波动状态下 5% 收益率分位数为 -0.006184，高波动状态下 5% 收益率分位数为 -0.028926，说明相同置信水平下的风险阈值会随市场状态显著改变。因此，固定窗口经验分位数虽然透明，但可能在状态切换时反应不足；这也是后续比较加权历史模拟、GARCH-t 和神经网络模型的原因。

2.4 自相关、波动代理变量与建模含义

图 2-6 比较了原始收益率和平方收益率的自相关函数。原始收益率自相关整体较弱，说明均值预测空间有限；但平方收益率的自相关更强，反映出波动率具有持续性。这个结果与金融时间序列的典型经验事实一致：收益率方向难以预测，但风险水平和波动状态可以建模。

图 2-7 和图 2-8 进一步考察了 $\log_ret$ 、 $rv5$ 和 bv 之间的关系。 $rv5$ 与 bv 的相关系数为 0.964，说明两个高频波动变量包含高度重叠的市场波动信息，但在跳跃或极端交易日也可能出现差异。第五章神经网络模型可以利用这类变量，在不预设线性条件方差方程的情况下学习尾部分位数。

2.5 VaR 预测与回测框架

基于上述数据事实，本文采用统一的滚动窗口 VaR 预测框架。预测目标是 $\log_ret$ 的一日 ahead 下尾 VaR，尾部概率设为 1%、5% 和 10%。为了避免 look-ahead bias，每个模型在预测日之前的信息集上估计，并只使用预测日前已经可观测的数据。

具体而言，本文使用 500 个交易日作为基础滚动窗口。设第 t 日的日对数收益率为 r_t ，在预测 r_{t+1} 的 VaR 时，模型只能使用窗口 $\{r_{t-499}, \dots, r_t\}$ 及同一窗口内的 $rv5$ 、 bv 等变量。窗口随后逐日向前滚动，形成样本外 VaR 预测序列。由于前 500 个交易日用于形成初始估计窗口，因此从第 501 个交易日开始进入样本外预测和回测阶段。对于神经网络分位数模型，滚动训练集同样遵循该时间顺序约束；对于 GARCH 类模型，参数估计和条件方差预测也仅基于滚动窗口内信息。

后续章节比较三类模型：

1. 第三章使用历史模拟法及其改进，包括普通历史模拟、时间加权历史模拟和 KDE 平滑加权历史模拟。2. 第四章使用 GARCH 类模型，重点考察 GARCH(1,1)-t 和 GJR-GARCH(1,1)-t 对厚尾和非对称波动的刻画能力。3. 第五章使用神经网络分位数回归，将滞后收益率和高频波动率变量输入 MLP，并通过 pinball loss 直接预测 VaR 分位数。

模型评价使用统一回测框架。首先，failure rate 用于比较实际 VaR 违约比例是否接近名义尾部概率。其次，Kupiec 无条件覆盖检验用于检验 VaR 违约率是否显著偏离理论水平。再次，Christoffersen 独立性检验和条件覆盖检验用于判断 VaR 违约是否存在聚集现象。最后，duration test 从违约间隔角度检验风险预测是否存在持续性失效，Lopez loss 则提供损失函数意义下的模型比较标准。第二章的可视化和统计检验表明，SPY 收益率同时具有厚尾、波动聚集和市场状态转换特征，因此第三章、第四章和第五章分别引入历史模拟、GARCH 类模型和神经网络模型具有明确的金融统计动机。

2.6 学术图表输出




图 2-1 SPY 日对数收益率及下尾观测值时间序列




图 2-2 已实现波动率与双幂变差的时间变化




图 2-3 SPY 日对数收益率的经验分布




图 2-4 SPY 日对数收益率的正态 Q-Q 图



图 2-5 SPY 日对数收益率的 60 日滚动波动率

Autocorrelation functions of returns and squared returns

ACF up to 40 trading-day lags; shaded band is an approximate 95% white-noise interval.




图 2-6 收益率与平方收益率的自相关函数

Correlation matrix of return and volatility variables

Pearson correlations among daily log returns, realized volatility, and bipower variation.




图 2-7 收益率与波动率变量的相关系数矩阵




图 2-8 已实现波动率与双幂变差的关系




图 2-9 按年份和月份划分的月度已实现波动率